



T.C.
SELÇUK ÜNİVERSİTESİ
FEN BİLİMLERİ ENSTİTÜSÜ

TÜRKÇE HUKUKİ METİNLERİN
ÖZETLENMESİNDE KÜÇÜK DİL
MODELLERİ VE KNOWLEDGE
DİSTİLLATION TABANLI BİR YAKLAŞIM

Keziban KARAGÜMÜŞ
258273001002
YÜKSEK LİSANS

Bilgisayar Mühendisliği Anabilim Dalı

05-2026
KONYA

İÇİNDEKİLER

İÇİNDEKİLER	iv
ÖZET	1
1. Giriş.....	1
2. PROBLEM TANIMI.....	2
2.1. Girdi	2
2.1. Çıktı	2
3. Veri Seti Oluşturma Süreci.....	2
3.1. Ham Karar Metinlerinin Toplanması.....	2
3.2. Karar Dosyaları ve Özet Dosyaları	3
3.3. Öğretmen Model ile Özet Üretimi	4
3.4. Karar ve Özet Dosyalarının Eşleştirilmesi.....	4
3.5. Nihai Veri Seti Dosyaları.....	5
4. Veri Ön İşleme	5
4.1. Metin Temizleme	5
4.2. Kullanılan Metin Bölümleri.....	6
5. Veri Seti Bölme Protokolü	6
6. Veri Seti Kartı	7
6.1. Veri Seti Adı	7
6.2. Amaç	7
6.3. Dil	7
6.4. Görev Türü.....	7
6.5. Veri Kaynağı.....	7
6.6. Veri Boyutu.....	7
6.7. Kategori Dağılımı	8
6.8. Veri Seti Adı	8
7. Kullanılan Modeller.....	8
7.1. SmolLM2-360M	8
7.2. TinyLlama-1.1B.....	8
7.3. Qwen2.5-1.5B	9

8. Fine-Tuning Stratejisi.....	9
8.1. Kullanılan Hiperparametreler	9
8.2. Eğitim Prompt Formatı	10
8.3. Inference Prompt Formatı	10
9. Deney Ortamı	10
10. Değerlendirme Metrikleri	11
11. Eğitim Süreci Detayları	11
11.1. Eğitim Süresi, GPU Bellek ve Kayıp Değerleri	11
11.2. Loss Eğrileri.....	12
12. Standart Sonuç Tablosu	13
13. Zero-Shot Baseline	13
14. Zero-Shot ve Fine-Tuned Karşılaştırması	14
15. Model Kartları	14
15.1. SmolLM2-360M Model Kartı	14
15.2. TinyLlama-1.1B Model Kartı	15
15.3. Qwen2.5-1.5B Model Kartı	16
16. Hata Analizi.....	16
16.1. Hata 1: Bozuk ve Tutarsız Dil Üretimi	16
16.2. Hata 2: Konu Dışına Çıkma.....	17
16.3. Hata 3: Hukuki Sonucun Yakalanamaması	17
16.4. Hata 4: Yüzeysel Özet ve Gerekçenin Kaybı	17
16.5. Hata 5: Modeller Arası Ortak Başarısızlık	18
17. Tartışma.....	18
18. Boyut-Performans Dengesi ve Edge Cihaz Değerlendirmesi.....	19
19. Kod ve Tekrarlanabilirlik	19
19.1. Temel bağımlılıklar.....	20
19.2. Kullanılan Seed Değerleri.....	20
19.3. Çalıştırma Adımları	21
20. Etik ve Lisans Değerlendirmesi	21
21. Sınırlılıklar	21
22. Gelecek Çalışmalar	21
23. Sonuç	22

ÖZET

Bu çalışmada Türkçe Danıştay kararlarının otomatik özetlenmesi problemi ele alınmıştır. Amaç, küçük ve orta ölçekli açık kaynak dil modellerinin Türkçe hukuki metin özetleme görevindeki performanslarını karşılaştırmalı olarak incelemektir. Bu kapsamda 40 adet Danıştay kararı ve bu kararlara karşılık gelen 40 adet öğretmen model özeti kullanılarak bir hukuki özetleme veri seti oluşturulmuştur. Veri seti %80 eğitim, %10 doğrulama ve %10 test olacak şekilde ayrılmıştır. Çalışmada SmoLLM2-360M, TinyLlama-1.1B ve Qwen2.5-1.5B modelleri QLoRA yöntemiyle fine-tune edilmiştir. Her model için zero-shot ve fine-tuned performansları ROUGE-1, ROUGE-2, ROUGE-L, BLEU, inference süresi, GPU bellek kullanımı ve model boyutu açısından değerlendirilmiştir. Deneyler 42, 123 ve 2026 olmak üzere üç farklı seed değeriyle tekrarlanmış ve sonuçlar ortalama $\pm$ standart sapma olarak raporlanmıştır. Bulgular, Qwen2.5-1.5B modelinin genel olarak en başarılı model olduğunu; ancak küçük veri seti ve hukuki özetleme görevinin zorluğu nedeniyle tüm modellerde belirgin hata türleri oluştuğunu göstermiştir.

1. Giriş

Hukuki metinler uzun, teknik ve yoğun anlam ilişkileri içeren metinlerdir. Danıştay kararları; dava konusu, tarafların iddiaları, maddi olay, hukuki değerlendirme ve karar sonucu gibi birçok önemli bileşenden oluşur. Bu kararların tamamını okumak zaman alıcıdır. Bu nedenle hukuki kararların otomatik olarak kısa ve anlamlı özetlere dönüştürülmesi hem hukuk alanında çalışan kişiler hem de doğal dil işleme araştırmaları için önemli bir problemidir.

Bu projede Türkçe hukuki metin özetleme görevi ele alınmıştır. Özellikle küçük dil modellerinin bu görevde ne kadar başarılı olabileceği araştırılmıştır. Büyük dil modelleri güçlü sonuçlar üretebilse de yüksek donanım gereksinimleri nedeniyle her ortamda çalıştırılmaz. Bu nedenle daha küçük modellerin QLoRA gibi verimli fine-tuning yöntemleriyle hukuki özetleme görevine uyarlanıp uyarlanamayacağı incelenmiştir.

Çalışmada benchmark protokolüne uygun olarak üç model seçilmiştir:

- SmoLLM2-360M
- TinyLlama-1.1B
- Qwen2.5-1.5B

2. PROBLEM TANIMI

Bu projenin amacı, uzun Danıştay kararlarını kısa ve anlamlı hukuki özetlere dönüştüren küçük dil modellerini karşılaştırmaktır.

2.1. Girdi

Modelin girdisi, Danıştay kararına ait uzun hukuki metindir. Karar metinlerinde genellikle şu bölümler bulunmaktadır:

- Dava konusu
- Temyiz iddiaları
- Karşı taraf savunması
- Maddi olay
- Hukuki değerlendirme
- Karar sonucu

2.1. Çıktı

Modelin üretmesi beklenen çıktı, 6-8 cümlelik Türkçe hukuki özetir. Bu özetin aşağıdaki bilgileri içermesi hedeflenmiştir:

- Davanın temel konusu
- Tarafların temel iddiaları
- Maddi olayın özü
- Hukuki değerlendirme
- Danıştay'ın vardığı sonuç

Bu görev klasik metin özetlemeye göre daha zordur. Çünkü hukuki metinlerde yalnızca konu başlığını özetlemek yeterli değildir. Kararın hukuki sonucu ve gerekçesi de doğru aktarılmalıdır.

3. Veri Seti Oluşturma Süreci

3.1. Ham Karar Metinlerinin Toplanması

Veri seti oluşturulurken Danıştay kararlarından yararlanılmıştır. Kararlar idare hukuku alanındaki farklı konulardan seçilmiştir. Veri setinde toplam 10 kategori bulunmaktadır:

1. Çevre
2. Disiplin
3. Eğitim
4. İhale
5. İmar
6. Kamu personeli
7. Ruhsat ve lisans
8. Sağlık
9. Sosyal güvenlik
10. Vergi

Her kategoriden 4 karar seçilmiştir. Böylece toplam 40 karar metni elde edilmiştir.

3.2. Karar Dosyaları ve Özet Dosyaları

Veri seti iki temel klasör üzerinden oluşturulmuştur:

- danistay_karar/
- danistay_ozet/

İlk klasörde karar metinleri, ikinci klasörde ise bu kararlara karşılık gelen öğretmen model özetleri yer almaktadır.

Karar dosyaları şu örüntüyle adlandırılmıştır:

cevre_1.txt

cevre_2.txt

...

vergi_4.txt

Özet dosyaları ise şu örüntüyle adlandırılmıştır:

cevre_ozet_1.txt

cevre_ozet_2.txt

...

vergi_ozet_4.txt

Bu yapı sayesinde karar ve özet dosyaları kategori adı ve sıra numarası üzerinden eşleştirilmiştir.

3.3. Öğretmen Model ile Özet Üretimi

Projede hedef özetleri oluşturmak için öğretmen model yaklaşımı kullanılmıştır. Her Danıştay kararı ChatGPT'ye manuel olarak verilmiş ve modelden hukuki anlamı koruyan kısa bir özet üretmesi istenmiştir.

Özet üretiminde kullanılan temel prompt şu mantıktadır:

Aşağıdaki Danıştay kararını hukuki anlamını koruyarak özetle.

Özette davanın konusunu, tarafların iddialarını, hukuki değerlendirmeyi ve karar sonucunu belirt.

Özet 6-8 cümle arasında olsun.

Karar numarası yazma. Kişi isimleri yazma. Metinde olmayan bilgi ekleme. Hukuki anlamı değiştirme. Tek paragraf halinde yaz. Sadece özeti üret.

Metni sade, açık ve akademik Türkçe ile yaz.

Bu işlem her karar için manuel olarak yapılmıştır. Yani kararlar tek tek ChatGPT'ye verilmiş, elde edilen özetler kontrol edilmiş ve ayrı .txt dosyalarına kaydedilmiştir.

Özet dosyaları şu biçimde adlandırılmıştır:

cevre_ozet_1.txt

cevre_ozet_2.txt

disiplin_ozet_1.txt

imar_ozet_4.txt

vergi_ozet_3.txt

Bu dosyalar danistay_ozet klasöründe yer almıştır.

3.4. Karar ve Özet Dosyalarının Eşleştirilmesi

Veri seti oluşturulurken karar dosyaları ile özet dosyaları kategori adı ve sıra numarasına göre eşleştirilmiştir.

Örneğin:

cevre_1.txt → cevre_ozet_1.txt

imar_4.txt → imar_ozet_4.txt

vergi_3.txt → vergi_ozet_3.txt
 ihale_2.txt → ihale_ozet_2.txt

Bu eşleştirme sonucunda 40 karar-özet çifti elde edilmiştir.

3.5. Nihai Veri Seti Dosyaları

Veri işleme sürecinin sonunda aşağıdaki dosyalar oluşturulmuştur:

danistay_40_teacher_final.csv
 train_40.csv
 validation_40.csv
 test_40.csv

Ana veri seti dosyası olan danistay_40_teacher_final.csv şu sütunları içermektedir:

Sütun	Açıklama
id	Her karar-özet çifti için benzersiz kimlik
category	Kararın hukuki kategorisi
karar_file	Kaynak karar dosyasının adı
ozet_file	Öğretmen özet dosyasının adı
model_input	Modele verilecek işlenmiş karar metni
summary	Öğretmen model tarafından oluşturulan referans özet

Burada model_input, modelin girişine verilecek işlenmiş karar metnini; summary ise öğretmen model tarafından oluşturulan hedef özeti temsil etmektedir.

4. Veri Ön İşleme

4.1. Metin Temizleme

Karar metinleri modele verilmeden önce temel temizlik işlemlerinden geçirilmiştir. Bu aşamada:

- Gereksiz boşluklar temizlenmiştir.

- Satır sonları düzenlenmiştir.
- Karar ve özet dosyalarının doğru eşleşip eşleşmediği kontrol edilmiştir.
- Çok kısa yakalanan örnekler tespit edilmiştir.
- Model giriş uzunlukları incelenmiştir.
- Eksik veya bozuk eşleşmeler düzeltilmiştir.

İlk aşamalarda bazı eğitim ve sağlık kategorilerindeki örneklerin model giriş uzunluklarının çok kısa yakalandığı görülmüştür. Bu durum bölüm ayrıştırma kurallarından kaynaklanmıştır. Daha sonra bu örnekler yeniden kontrol edilerek anlamlı karar bölümlerinin modele girecek şekilde düzeltilmesi sağlanmıştır.

4.2. Kullanılan Metin Bölümleri

Danıştay kararları her zaman aynı biçimsel yapıya sahip değildir. Bazı kararlarda “DAVA KONUSU”, “MADDİ OLAY”, “HUKUKİ DEĞERLENDİRME” ve “KARAR SONUCU” başlıkları açıkça yer alırken, bazı kararlarda bu başlıklar farklı biçimde yazılmıştır.

Özetleme görevi için özellikle şu bölümler önemli görülmüştür:

- Dava konusu
- Maddi olay
- Hukuki değerlendirme
- Karar sonucu

Ancak tüm kararlarda bu bölümler aynı formatta bulunmadığından, yalnızca katı bir bölüm çıkarma yöntemi kullanılmamış, metnin özetleme için anlamlı kısmının korunmasına odaklanılmıştır. Kararlarda bu bölümler incelenmiş olmakla birlikte, veri setinin büyük kısmında karar metinleri bütün halinde modele verilmiştir.

5. Veri Seti Bölme Protokolü

Veri seti ortak benchmark gereksinimine uygun olarak %80 eğitim, %10 doğrulama ve %10 test olacak şekilde ayrılmıştır.

Bölüm	Örnek Sayısı	Oran
Eğitim	32	%80
Doğrulama	4	%10

Test	4	%10
Toplam	40	%100

Bölme işlemi sırasında random_state=42 kullanılmıştır. Böylece deneylerin tekrarlanabilirliği sağlanmıştır.

6. Veri Seti Kartı

6.1. Veri Seti Adı

Danıştay Kararları Türkçe Hukuki Özetleme Veri Seti

6.2. Amaç

Bu veri seti, Türkçe Danıştay kararlarının otomatik olarak özetlenmesi amacıyla oluşturulmuştur.

6.3. Dil

Türkçe

6.4. Görev Türü

Abstractive Text Summarization

6.5. Veri Kaynağı

Kaynak metinler Danıştay kararlarından oluşmaktadır. Hedef özetler öğretmen model yaklaşımıyla ChatGPT kullanılarak üretilmiştir

6.6. Veri Boyutu

Özellik	Değer
Karar sayısı	40
Özet sayısı	40
Kategori sayısı	10
Eğitim örneği	32
Doğrulama örneği	4
Test örneği	4

6.7. Kategori Dağılımı

Kategori	Örnek Sayısı
Çevre	4
Disiplin	4
Eğitim	4
İhale	4
İmar	4
Kamu personeli	4
Ruhsat ve lisans	4
Sağlık	4
Sosyal güvenlik	4
Vergi	4

6.8. Veri Seti Adı

Veri seti akademik çalışma amacıyla hazırlanmıştır. Hukuki karar metinleri kamuya açık karar metinleri olmakla birlikte, kişisel veri içerebilecek unsurların raporda açık biçimde paylaşılmamasına dikkat edilmiştir. Öğretmen model özetleri hukuki uzman onayından geçmediği için bu veri seti doğrudan hukuki danışmanlık amacıyla kullanılmamalıdır.

7. Kullanılan Modeller

Çalışmada benchmark protokolüne uygun olarak üç model kullanılmıştır.

7.1. SmoLLM2-360M

SmoLLM2-360M, küçük parametre sayısı nedeniyle edge ve düşük kaynaklı cihazlara uygunluk açısından önemlidir. Bu çalışmada en küçük baseline model olarak kullanılmıştır.

- Model: SmoLLM2-360M-Instruct
- Parametre sayısı: 360M
- Görev: Türkçe hukuki özetleme
- Fine-tuning yöntemi: QLoRA

7.2. TinyLlama-1.1B

TinyLlama-1.1B, orta ölçekli ve genel amaçlı bir açık kaynak dil modelidir. SmolLM2'ye göre daha yüksek parametre sayısına sahiptir.

- Model: TinyLlama-1.1B-Chat-v1.0
- Parametre sayısı: 1.1B
- Görev: Türkçe hukuki özetleme
- Fine-tuning yöntemi: QLoRA

7.3. Qwen2.5-1.5B

Qwen2.5-1.5B, çok dilli kapasitesi güçlü olan ve Türkçe metinlerde daha başarılı olması beklenen bir modeldir.

- Model: Qwen2.5-1.5B-Instruct
- Parametre sayısı: 1.5B
- Görev: Türkçe hukuki özetleme
- Fine-tuning yöntemi: QLoRA

8. Fine-Tuning Stratejisi

Bu çalışmada tüm modeller için QLoRA yöntemi kullanılmıştır. QLoRA, modelleri düşük bellek kullanımıyla fine-tune etmeyi mümkün kılar. Özellikle Colab gibi sınırlı GPU belleğine sahip ortamlarda tam fine-tuning yapmak zor olduğundan QLoRA uygun bir tercih olmuştur.

8.1. Kullanılan Hiperparametreler

Hiperparametre	Değer
Epoch	3
Learning rate	2e-4
Batch size	1
Gradient accumulation steps	4
Max sequence length	1024
LoRA rank	8
LoRA alpha	16
LoRA dropout	0.05

Target modules	q_proj, v_proj
Quantization	4-bit
Seeds	42, 123, 2026

8.2. Eğitim Prompt Formatı

Eğitim sırasında her örnek aşağıdaki formata dönüştürülmüştür:

Aşağıdaki Danıştay kararını 6-8 cümlelik Türkçe hukuki özet haline getir.

Karar:

{model_input}

Özet:

{summary}

Burada model_input karar metnini, summary ise öğretmen model tarafından üretilen referans özeti ifade eder.

8.3. Inference Prompt Formatı

Test aşamasında özet kısmı boş bırakılmıştır:

Aşağıdaki Danıştay kararını 6-8 cümlelik Türkçe hukuki özet haline getir.

Karar:

{model_input}

Özet:

9. Deney Ortamı

Deneyler Google Colab GPU ortamında gerçekleştirilmiştir. Eğitim sürecinde 4-bit quantization ve QLoRA kullanılmıştır.

Kullanılan başlıca kütüphaneler:

transformers

accelerate
 peft
 bitsandbytes
 torch
 pandas
 numpy
 scikit-learn
 evaluate
 rouge_score
 sacrebleu
 sentencepiece
 matplotlib

10. Değerlendirme Metrikleri

Bu görev bir üretim görevi olduğu için aşağıdaki metrikler kullanılmıştır:

- ROUGE-1
- ROUGE-2
- ROUGE-L
- BLEU
- Inference süresi
- GPU bellek kullanımı
- Model boyutu

ROUGE metrikleri model çıktısı ile referans özet arasındaki örtüşmeyi ölçmektedir. BLEU metriği ise n-gram tabanlı benzerliği değerlendirmektedir. Ayrıca modellerin pratik kullanılabilirliğini değerlendirmek için inference süresi, GPU bellek tüketimi ve adapter model boyutu da raporlanmıştır.

11. Eğitim Süreci Detayları

Her model 3 epoch boyunca eğitilmiştir. Learning rate $2e-4$, batch size 1 ve gradient accumulation steps 4 olarak kullanılmıştır. Deneyler üç farklı seed ile tekrar edilmiştir.

11.1. Eğitim Süresi, GPU Bellek ve Kayıp Değerleri

Model	Train Loss	Val Loss	Eğitim Süresi sn	GPU Bellek GB
SmolLM2-360M	2.6213 ± 0.0014	2.7904 ± 0.0009	44.04 ± 2.55	4.401 ± 0.001
TinyLlama-1.1B	2.1194 ± 0.0022	2.0759 ± 0.0061	117.69 ± 1.10	1.895 ± 0.006
Qwen2.5-1.5B	2.8108 ± 0.0055	2.9442 ± 0.0104	137.86 ± 8.64	3.912 ± 0.005

11.2. Loss Eğrileri

Temsili eğitim koşusuna ait epoch bazlı loss değerleri aşağıdaki gibidir:

Model	Epoch	Train Loss	Validation Loss
SmolLM2-360M	1	2.2842	4.8828
SmolLM2-360M	2	4.7831	4.7671
SmolLM2-360M	3	7.0577	4.7137
TinyLlama-1.1B	1	2.0492	2.3857
TinyLlama-1.1B	2	2.1306	2.1782
TinyLlama-1.1B	3	2.0555	2.0758
Qwen2.5-1.5B	1	2.6012	3.2345
Qwen2.5-1.5B	2	2.8511	2.9978
Qwen2.5-1.5B	3	2.8585	2.9169

TinyLlama ve Qwen2.5 modellerinde validation loss değerleri düzenli biçimde azalmıştır. SmolLM2 modelinde validation loss hafif azalmış, ancak training loss artmıştır. Bu durum SmolLM2 eğitiminin daha kararsız ilerlediğini göstermektedir. Buna rağmen SmolLM2 tamamen başarısız olmamış ve bazı metriklerde TinyLlama'dan daha iyi sonuç üretmiştir.

Loss eğrileri şu dosyalara kaydedilmiştir:

results/loss_curves/SmolLM2_360M_loss_curve.png

results/loss_curves/TinyLlama_11B_loss_curve.png

results/loss_curves/Qwen25_15B_loss_curve.png

results/loss_curves/validation_loss_comparison.png

12. Standart Sonuç Tablosu

Aşağıdaki tablo, fine-tuned modellerin 3 seed ortalaması $\pm$ standart sapma sonuçlarını göstermektedir.

Model	Parametre	FT Yöntemi	ROUGE-1	ROUGE-L	BLEU	Eğitim Süresi sn	Inferenç ms/örnek	GPU Bellek GB	Model Boyutu MB
SmolLM2-360M	360M	QLoRA	0.1295 $\pm$ 0.0032	0.0743 $\pm$ 0.0040	0.0811 $\pm$ 0.0061	44.04 $\pm$ 2.55	17182.38 $\pm$ 1052.13	4.401 $\pm$ 0.001	35.09
TinyLlama-1.1B	1.1B	QLoRA	0.1118 $\pm$ 0.0175	0.0681 $\pm$ 0.0087	0.0580 $\pm$ 0.0409	117.69 $\pm$ 1.10	12063.76 $\pm$ 2758.80	1.895 $\pm$ 0.006	46.78
Qwen2.5-1.5B	1.5B	QLoRA	0.1822 $\pm$ 0.0042	0.0977 $\pm$ 0.0034	0.4085 $\pm$ 0.1189	137.86 $\pm$ 8.64	26652.82 $\pm$ 866.93	3.912 $\pm$ 0.005	52.89

Qwen2.5-1.5B modeli ROUGE-1, ROUGE-L ve BLEU metriklerinde en yüksek performansı elde etmiştir. SmolLM2-360M modeli, parametre sayısı daha düşük olmasına rağmen TinyLlama-1.1B modelini bazı metriklerde geçmiştir. Bu sonuç, model parametre sayısının tek başına performansı belirlemediğini göstermektedir.

13. Zero-Shot Baseline

Fine-tuning öncesinde her model aynı test seti üzerinde zero-shot olarak değerlendirilmiştir.

Model	ROUGE-1	ROUGE-2	ROUGE-L	BLEU	Inference ms/örnek
SmolLM2-360M	0.0878	0.0016	0.0536	0.1473	12872.69
TinyLlama-1.1B	0.0891	0.0079	0.0534	0.0217	11528.50
Qwen2.5-	0.1735	0.0240	0.0960	0.4544	25588.65

1.5B					
------	--	--	--	--	--

Zero-shot sonuçlarına göre Qwen2.5-1.5B modeli fine-tuning öncesinde de en yüksek performansı göstermiştir. Bu durum modelin çok dilli ön eğitim kapasitesinin Türkçe hukuki metinlerde avantaj sağladığını düşündürmektedir.

14. Zero-Shot ve Fine-Tuned Karşılaştırması

Model	Durum	ROUGE-1	ROUGE-2	ROUGE-L	BLEU	Inference ms/örnek
SmolLM2-360M	Zero-shot	0.0878	0.0016	0.0536	0.1473	12872.69
SmolLM2-360M	Fine-tuned	0.1295	0.0030	0.0743	0.0811	17182.38
TinyLlama-1.1B	Zero-shot	0.0891	0.0079	0.0534	0.0217	11528.50
TinyLlama-1.1B	Fine-tuned	0.1118	0.0080	0.0681	0.0580	12063.76
Qwen2.5-1.5B	Zero-shot	0.1735	0.0240	0.0960	0.4544	25588.65
Qwen2.5-1.5B	Fine-tuned	0.1822	0.0254	0.0977	0.4085	26652.82

SmolLM2 ve TinyLlama modellerinde fine-tuning sonrasında ROUGE metriklerinde artış gözlenmiştir. Qwen2.5-1.5B modelinde ise ROUGE-1 ve ROUGE-L değerleri hafif artmış, BLEU değeri ise düşmüştür. Bu durum fine-tuning sonrasında modelin referans özetlerle birebir n-gram benzerliğinin azaldığını, ancak ROUGE bakımından içerik örtüşmesini kısmen artırdığını düşündürmektedir.

15. Model Kartları

15.1. SmolLM2-360M Model Kartı

Alan	Açıklama
Model adı	SmolLM2-360M-Instruct
Kaynak	HuggingFaceTB
Parametre sayısı	360M

Alan	Açıklama
Görev	Türkçe Danıştay kararı özetleme
Eğitim verisi	40 karar-özet çifti
Dil	Türkçe
Fine-tuning yöntemi	QLoRA
Epoch	3
Learning rate	2e-4
Batch size	1
Gradient accumulation	4
Seeds	42, 123, 2026
ROUGE-1	0.1295 $\pm$ 0.0032
ROUGE-L	0.0743 $\pm$ 0.0040
BLEU	0.0811 $\pm$ 0.0061
GPU gereksinimi	Yaklaşık 4.4 GB
Limitasyon	Uzun hukuki metinlerde kararsızlık ve tekrar riski
Bias riski	Öğretmen model özetlerinden gelen ifade ve yorum kalıplarını öğrenebilir

15.2. TinyLlama-1.1B Model Kartı

Alan	Açıklama
Model adı	TinyLlama-1.1B-Chat-v1.0
Kaynak	TinyLlama Team
Parametre sayısı	1.1B
Görev	Türkçe Danıştay kararı özetleme
Eğitim verisi	40 karar-özet çifti
Dil	Türkçe
Fine-tuning yöntemi	QLoRA
Epoch	3
Learning rate	2e-4
Batch size	1
Gradient accumulation	4
Seeds	42, 123, 2026
ROUGE-1	0.1118 $\pm$ 0.0175
ROUGE-L	0.0681 $\pm$ 0.0087
BLEU	0.0580 $\pm$ 0.0409
GPU gereksinimi	Yaklaşık 1.9 GB
Limitasyon	Hukuki gerekçe ve karar sonucunu yakalamada zayıf
Bias riski	Küçük veri setindeki özetleme tarzına aşırı uyum gösterebilir

15.3. Qwen2.5-1.5B Model Kartı

Alan	Açıklama
Model adı	Qwen2.5-1.5B-Instruct
Kaynak	Qwen Team
Parametre sayısı	1.5B
Görev	Türkçe Danıştay kararı özetleme
Eğitim verisi	40 karar-özet çifti
Dil	Türkçe
Fine-tuning yöntemi	QLoRA
Epoch	3
Learning rate	2e-4
Batch size	1
Gradient accumulation	4
Seeds	42, 123, 2026
ROUGE-1	0.1822 $\pm$ 0.0042
ROUGE-L	0.0977 $\pm$ 0.0034
BLEU	0.4085 $\pm$ 0.1189
GPU gereksinimi	Yaklaşık 3.9 GB
Limitasyon	Daha yavaş inference ve bazı örneklerde bozuk üretim
Bias riski	Öğretmen modelin özetleme tarzını ve olası hatalarını öğrenebilir

16. Hata Analizi

Hata analizi, modellerin hangi durumlarda başarısız olduğunu anlamak amacıyla yapılmıştır. Test çıktıları incelendiğinde özellikle Qwen2.5-1.5B modelinin genel metriklerde en iyi model olmasına rağmen bazı örneklerde ciddi üretim hataları yaptığı görülmüştür.

16.1. Hata 1: Bozuk ve Tutarsız Dil Üretimi

Karar ID: imar_1

Kategori: imar

Model: Qwen2.5-1.5B

Referans özet, belediye meclisince kabul edilen imar ve şehircilik müdürlüğü ücret tarifeleri ile bu kapsamda ödenen bedellerin iadesi hakkındadır. Model çıktısında

ise “hidrofor projesi”, “tetkik üyesi” ve farklı para tutarları etrafında bozuk bir metin üretilmiştir.

Bu hata, modelin karar metnindeki bazı kelime parçalarını yakaladığını ancak bunları anlamlı bir hukuki özet yapısına dönüştüremediğini göstermektedir.

16.2. Hata 2: Konu Dışına Çıkma

Karar ID: ihale_1

Kategori: ihale

Model: Qwen2.5-1.5B

Referans özet, bir maden sahasına ilişkin arama ruhsatı talebinin reddedilmesi ve bu işlemin hukuka uygunluğu hakkındadır. Model çıktısında ise bağlam dışı yer ve olay ifadeleri üretilmiştir.

Bu durum hallucination ve konu sapması olarak değerlendirilmiştir.

16.3. Hata 3: Hukuki Sonucun Yakalanamaması

Karar ID: imar_4

Kategori: imar

Model: Qwen2.5-1.5B

Referans özet, taşınmazların niteliğine ilişkin eksik inceleme ve mahkeme kararının bozulması gibi hukuki sonucu içermektedir. Model çıktısı ise kararın temel sonucunu açık biçimde verememiştir.

Bu hata, modelin olay örgüsünü kısmen yakalasa bile “bozma”, “eksik inceleme” ve “hukuki nitelik” gibi kritik unsurları koruyamadığını göstermektedir.

16.4. Hata 4: Yüzeysel Özet ve Gerekçenin Kaybı

Karar ID: ruhsat_lisans_4

Kategori: ruhsat_lisans

Model: Qwen2.5-1.5B

Referans özet Akkuyu Nükleer Güç Santrali projesi, soğutma suyu yeterliliği, çevresel etki değerlendirmesi ve izin süreçleri gibi unsurları içermektedir. Model çıktısı Akkuyu bağlamını kısmen yakalamış olsa da hukuki gerekçeyi ve karar sonucunu yeterince açık verememiştir.

16.5. Hata 5: Modeller Arası Ortak Başarısızlık

SmolLM2, TinyLlama ve Qwen çıktıları karşılaştırıldığında ortak hata türleri şunlardır:

- Ana uyuşmazlığı kaçırma
- Hukuki gerekçeyi yüzeysel aktarma
- Karar sonucunu eksik verme
- Bağlam dışı bilgi üretme
- Tekrar veya bozuk dil üretme

Bu hatalar yalnızca tek bir modele özgü değildir. Temel nedenler veri setinin küçük olması, metinlerin uzunluğu ve hukuki özetleme görevinin uzmanlık gerektirmesidir.

17. Tartışma

Sonuçlara göre Qwen2.5-1.5B modeli en başarılı modeldir. Hem zero-shot hem fine-tuned deneylerde genel olarak en yüksek ROUGE ve BLEU değerlerini üretmiştir. Bu durum Qwen modelinin çok dilli ön eğitim kapasitesinin Türkçe hukuki metinlerde avantaj sağladığını göstermektedir.

SmolLM2-360M, parametre sayısı en düşük model olmasına rağmen TinyLlama-1.1B modelinden daha iyi sonuçlar elde etmiştir. Bu önemli bir bulgudur. Çünkü parametre sayısının tek başına başarıyı belirlemediğini göstermektedir.

TinyLlama-1.1B modeli daha düşük validation loss değerlerine ulaşmış olsa da özetleme metriklerinde en başarılı model olamamıştır. Bu durum eğitim kaybının üretim kalitesiyle birebir örtüşmediğini göstermektedir.

Genel olarak tüm modellerde en büyük sorun, hukuki karar sonucunun ve gerekçenin doğru biçimde özetlenememesidir. Bu problem özellikle küçük veri setlerinde daha belirgin hale gelmiştir.

Genel olarak modellerin başarısını sınırlayan temel faktörler şunlardır:

- Veri setinin yalnızca 40 örnekten oluşması
- Test setinin yalnızca 4 örnek olması
- Karar metinlerinin çok uzun olması
- 1024 token sınırı nedeniyle bazı karar bölümlerinin kesilmesi
- Hedef özetlerin insan uzmanlar yerine öğretmen modelden üretilmesi
- Hukuki özetleme görevinin yüksek uzmanlık gerektirmesi

18. Boyut-Performans Dengesi ve Edge Cihaz Değerlendirmesi

Model	Model Boyutu MB	Inference ms/örnek	Performans Yorumu
SmolLM2-360M	35.09	17182.38	Küçük boyutlu, orta düzey performans
TinyLlama-1.1B	46.78	12063.76	Daha hızlı fakat düşük metrikler
Qwen2.5-1.5B	52.89	26652.82	En iyi performans fakat en yavaş inference

- SmolLM2 küçük model boyutu nedeniyle edge cihazlara daha uygun görünmektedir. TinyLlama inference açısından daha hızlıdır; ancak metriklerde beklenen performansı gösterememiştir. Qwen2.5 en yüksek performansı sağlamıştır fakat inference süresi daha yüksektir. Bu nedenle Qwen daha çok sunucu tabanlı kullanım için, SmolLM2 ise kaynak kısıtlı ortamlar için daha uygundur.

19. Kod ve Tekrarlanabilirlik

Proje dosya yapısı aşağıdaki gibi düzenlenmiştir:

datasets/

danistay_40_teacher_final.csv

train_40.csv

validation_40.csv

test_40.csv

zero_shot_results.csv

model_sizes.csv

models/

smollm2_danistay_40/

tinylama_danistay_40/

qwen25_15b_danistay_40/

seed_runs/

SmolLM2-360M_3seed_results.csv

TinyLlama-1.1B_3seed_results.csv

Qwen2.5-1.5B_3seed_results.csv

results/

final_benchmark_table.csv

zero_vs_finetuned_table.csv

loss_curves/

docs/

dataset_card.md

model_cards.md

error_analysis.md

README.md

requirements.txt

19.1. Temel bağımlılıklar

transformers

accelerate

peft

bitsandbytes

torch

pandas

numpy

scikit-learn

evaluate

rouge_score

sacrebleu

sentencepiece

matplotlib

19.2. Kullanılan Seed Değerleri

42

123

2026

19.3. Çalıştırma Adımları

1. Veri seti oluşturma notebooku çalıştırılır.
2. Train/validation/test dosyaları oluşturulur.
3. Zero-shot benchmark çalıştırılır.
4. Her model QLoRA ile fine-tune edilir.
5. 3 seed deneyleri çalıştırılır.
6. ROUGE, BLEU, inference süresi ve GPU bellek ölçülür.
7. Final benchmark tabloları oluşturulur.
8. Loss eğrileri oluşturulur.
9. Hata analizi yapılır.

20. Etik ve Lisans Değerlendirmesi

Bu çalışmada kullanılan metinler hukuki karar metinleridir. Veri seti akademik çalışma amacıyla oluşturulmuştur.

Özetler öğretmen model tarafından üretildiği için, bu özetlerin hukuki uzman onayından geçmediği özellikle belirtilmelidir. Bu nedenle veri seti doğrudan hukuki danışmanlık veya karar destek sistemi olarak kullanılmamalıdır.

Fine-tuned modellerin çıktıları da hukuki karar yerine geçmez. Modeller yalnızca araştırma ve benchmark amacıyla değerlendirilmiştir.

21. Sınırlılıklar

Bu çalışmanın başlıca sınırlılıkları şunlardır:

1. Veri seti yalnızca 40 karar-özet çiftinden oluşmaktadır.
2. Özetler hukuk uzmanları tarafından değil, öğretmen model yaklaşımıyla üretilmiştir.
3. Test seti yalnızca 4 örnektir.
4. Modeller uzun hukuki bağlamları tam olarak öğrenmekte zorlanmıştır.
5. QLoRA yöntemi bellek verimliliği sağlasa da modelin tüm parametreleri güncellenmediği için performans sınırlı kalmış olabilir.
6. Hukuki özetleme görevi, yalnızca metin benzerliği metrikleriyle tam olarak değerlendirilemeyebilir.
7. İnsan uzman değerlendirmesi yapılmamıştır.

22. Gelecek Çalışmalar

Bu çalışmanın geliştirilmesi için aşağıdaki adımlar önerilmektedir:

1. Veri seti 40 örnekten en az 200-500 örneğe çıkarılmalıdır.
2. Öğretmen model özetleri hukuk uzmanları tarafından kontrol edilmelidir.
3. Test seti büyütülmelidir.
4. Kararlar bölüm bazlı işlenmelidir.
5. Daha uzun context window destekleyen modeller denenmelidir.
6. Gemma 4 E2B, Phi veya mT5 gibi ek modeller karşılaştırılmalıdır.
7. ROUGE ve BLEU yanında BERTScore veya insan değerlendirmesi kullanılmalıdır.
8. Hukuki doğruluk için uzman değerlendirmesi yapılmalıdır.
9. Edge cihazlarda gerçek inference testleri yapılmalıdır.

23. Sonuç

Bu çalışmada Türkçe Danıştay kararlarının otomatik özetlenmesi görevi için üç küçük/orta ölçekli açık kaynak dil modeli karşılaştırılmıştır. SmolLM2-360M, TinyLlama-1.1B ve Qwen2.5-1.5B modelleri QLoRA yöntemiyle fine-tune edilmiş, zero-shot ve fine-tuned performansları karşılaştırılmıştır.

Deney sonuçlarına göre Qwen2.5-1.5B modeli en yüksek ROUGE ve BLEU değerlerini elde etmiştir. Ancak hata analizi, en iyi modelin bile hukuki özetleme görevinde tutarlı ve güvenilir sonuç üretmekte zorlandığını göstermiştir. Özellikle hukuki gerekçenin ve karar sonucunun doğru aktarılması, modeller için en zor kısımlardan biri olmuştur.

Genel bulgular, küçük veri setleriyle hukuki özetleme görevinin başarılı biçimde öğrenilmesinin zor olduğunu göstermektedir. Buna rağmen çalışma, Türkçe hukuki metin özetleme alanında küçük dil modelleri için tekrarlanabilir bir benchmark süreci ortaya koymuştur. Elde edilen sonuçlar, daha büyük ve uzman denetimli veri setleriyle yapılacak gelecek çalışmalar için temel bir karşılaştırma noktası sunmaktadır.