



# **TÜRKÇE HUKUKİ METİNLERİN ÖZETLENMESİNDE KÜÇÜK DİL MODELLERİ VE KNOWLEDGE DISTILLATION TABANLI BİR YAKLAŞIM**

**Keziban KARAGUMUS**  
**258273001002**



# SUNUM PLANI

- Problem Tanımı
- Motivasyon
- Veri Seti Oluşturma Süreci
- Knowledge Distillation Yaklaşımı
- Kullanılan Modeller Fine-Tuning Stratejisi
- Deney Ortamı
- Sonuçlar
- Zero-Shot Karşılaştırması
- Hata Analizi
- Model Kartları
- Tartışma ve Gelecek Çalışmalar



# PROBLEM TANIMI

## •Amaç:

Uzun Danıştay kararlarını kısa ve anlamlı hukuki özetlere dönüştürmek.

## Girdi:

- Dava konusu
- Tarafların iddiaları
- Maddi olay
- Hukuki değerlendirme
- Karar sonucu

## Çıktı:

- 6-8 cümlelik hukuki özet

## Zorluk:

- Çok uzun metinler
- Teknik hukuk dili
- Karar mantığının korunması gerekliliği



# NEDEN BU PROBLEM ÖNEMLİ?

- **Hukuki metinler**
  - Uzunudur
  - Karmaşıktır
  - Teknik terminoloji içerir
- **Manuel inceleme**
  - Çok zaman alır
- **Otomatik özetleme**
  - Hukukçular için zaman kazancı
  - Karar inceleme süreçlerinde hız



# VERİ PROBLEMİ

- Hukuki özetleme çalışmalarındaki en büyük problem:
- Referans özet eksikliği**
- Danıştay kararlarının çoğunda:
- Kalıplaşmış yapılar bulunmakta
- Bu nedenle:
- Knowledge Distillation yaklaşımı kullanıldı**
- Teacher Model:
- ChatGPT
- Student Models:
- SmolLM2
- TinyLlama
- Qwen



# VERİ SETİ OLUŞTURMA

| Özellik         | Değer |
|-----------------|-------|
| Karar Sayısı    | 40    |
| Özet Sayısı     | 40    |
| Kategori Sayısı | 10    |

## **Kategoriler:**

Çevre  
Disiplin  
Eğitim  
İhale  
İmar  
Kamu Personeli  
Ruhsat-Lisans  
Sağlık  
Sosyal Güvenlik  
Vergi



# ÖĞRETMEN MODEL (TEACHER MODEL)

Neden Teacher Model kullandık?

- Gerçek özet veri seti bulunmuyor.
- Kararlar oldukça kalıplaşmış yapıda.
- Student modellerin öğrenebilmesi için referans özet gerekli.
- Teacher Model:

## ChatGPT

- Görev:
- Uzun Danıştay kararlarından yüksek kaliteli özet üretmek.



# KULLANILAN PROMPT

- Aşağıdaki Danıştay kararını hukuki anlamını koruyarak özetle.

Özette:

- Davanın konusu
- Tarafların iddiaları
- Hukuki değerlendirme
- Karar sonucu yer alsın.

Özet:

- 6–8 cümle olsun
- Karar numarası verme
- Kişi isimleri verme
- Yeni bilgi ekleme
- Hukuki anlamı değiştirme





# VERİ SETİ BÖLME

| Bölüm      | Sayı | Oran |
|------------|------|------|
| Train      | 32   | %80  |
| Validation | 4    | %10  |
| Test       | 4    | %10  |

Random State:  
42



# KULLANILAN MODELLER

| Model     | Parametre |
|-----------|-----------|
| SmolLM2   | 360M      |
| TinyLlama | 1.1B      |
| Qwen2.5   | 1.5B      |



# NEDEN QLoRA?

## QLoRA

Avantajlar:

- Düşük GPU belleği
- Hızlı eğitim
- Düşük maliyet
- Colab uyumluluğu



# HİPERPARAMETRELER

| Hiperparametre              | Değer          |
|-----------------------------|----------------|
| Epoch                       | 3              |
| Learning rate               | 2e-4           |
| Batch size                  | 1              |
| Gradient accumulation steps | 4              |
| Max sequence length         | 1024           |
| LoRA rank                   | 8              |
| LoRA alpha                  | 16             |
| LoRA dropout                | 0.05           |
| Target modules              | q_proj, v_proj |
| Quantization                | 4-bit          |
| Seeds                       | 42, 123, 2026  |



# DENEY ORTAMI

Deneyler Google Colab GPU ortamında gerçekleştirilmiştir. Eğitim sürecinde 4-bit quantization ve QLoRA kullanılmıştır.

Kullanılan başlıca kütüphaneler:

transformers

accelerate

peft

bitsandbytes

torch

pandas

numpy

scikit-learn

evaluate

rouge\_score

sacrebleu

sentencepiece

matplotlib



# Değerlendirme Metrikleri

Bu görev bir üretim görevi olduğu için aşağıdaki metrikler kullanılmıştır:

- ROUGE-1
- ROUGE-2
- ROUGE-L
- BLEU
- Inference süresi
- GPU bellek kullanımı
- Model boyutu

ROUGE metrikleri model çıktısı ile referans özet arasındaki örtüşmeyi ölçmektedir. BLEU metriği ise n-gram tabanlı benzerliği değerlendirmektedir. Ayrıca modellerin pratik kullanılabilirliğini değerlendirmek için inference süresi, GPU bellek tüketimi ve adapter model boyutu da raporlanmıştır.



# Eğitim Süreci Detayları

Her model 3 epoch boyunca eğitilmiştir. Learning rate  $2e-4$ , batch size 1 ve gradient accumulation steps 4 olarak kullanılmıştır. Deneyler üç farklı seed ile tekrar edilmiştir.



# Eğitim Süresi, GPU Bellek ve Kayıp Değerleri


| Model          | Train Loss      | Val Loss        | Eğitim Süresi<br>sn | GPU Bellek<br>GB |
|----------------|-----------------|-----------------|---------------------|------------------|
| SmolLM2-360M   | 2.6213 ± 0.0014 | 2.7904 ± 0.0009 | 44.04 ± 2.55        | 4.401 ± 0.001    |
| TinyLlama-1.1B | 2.1194 ± 0.0022 | 2.0759 ± 0.0061 | 117.69 ± 1.10       | 1.895 ± 0.006    |
| Qwen2.5-1.5B   | 2.8108 ± 0.0055 | 2.9442 ± 0.0104 | 137.86 ± 8.64       | 3.912 ± 0.005    |






# Loss Eğrileri


Qwen2.5-1.5B Loss Curve




SmolLM2-360M Loss Curve



TinyLlama-1.1B Loss Curve



Validation Loss Comparison





# Loss Eğrileri

TinyLlama ve Qwen2.5 modellerinde validation loss değerleri düzenli biçimde azalmıştır. SmolLM2 modelinde validation loss hafif azalmış, ancak training loss artmıştır. Bu durum SmolLM2 eğitiminin daha kararsız ilerlediğini göstermektedir. Buna rağmen SmolLM2 tamamen başarısız olmamış ve bazı metriklerde TinyLlama'dan daha iyi sonuç üretmiştir.



# Standart Sonuç Tablosu

| Model          | Parametre | FT Yöntemi | ROUGE-1             | ROUGE-L             | BLEU                | Eğitim Süresi sn  | Inferenç ms/örnek      | GPU Bellek GB     | Model Boyutu MB |
|----------------|-----------|------------|---------------------|---------------------|---------------------|-------------------|------------------------|-------------------|-----------------|
| SmolLM2-360M   | 360M      | QLoRA      | $0.1295 \pm 0.0032$ | $0.0743 \pm 0.0040$ | $0.0811 \pm 0.0061$ | $44.04 \pm 2.55$  | $17182.38 \pm 1052.13$ | $4.401 \pm 0.001$ | 35.09           |
| TinyLlama-1.1B | 1.1B      | QLoRA      | $0.1118 \pm 0.0175$ | $0.0681 \pm 0.0087$ | $0.0580 \pm 0.0409$ | $117.69 \pm 1.10$ | $12063.76 \pm 2758.80$ | $1.895 \pm 0.006$ | 46.78           |
| Qwen2.5-1.5B   | 1.5B      | QLoRA      | $0.1822 \pm 0.0042$ | $0.0977 \pm 0.0034$ | $0.4085 \pm 0.1189$ | $137.86 \pm 8.64$ | $26652.82 \pm 866.93$  | $3.912 \pm 0.005$ | 52.89           |



# Zero-Shot Baseline

Zero-shot sonuçlarına göre Qwen2.5-1.5B modeli fine-tuning öncesinde de en yüksek performansı göstermiştir. Bu durum modelin çok dilli ön eğitim kapasitesinin Türkçe hukuki metinlerde avantaj sağladığını düşündürmektedir.

| Model              | ROUGE-1 | ROUGE-2 | ROUGE-L | BLEU   | Inference<br>ms/örnek |
|--------------------|---------|---------|---------|--------|-----------------------|
| SmolLM2-<br>360M   | 0.0878  | 0.0016  | 0.0536  | 0.1473 | 12872.69              |
| TinyLlama-<br>1.1B | 0.0891  | 0.0079  | 0.0534  | 0.0217 | 11528.50              |
| Qwen2.5-<br>1.5B   | 0.1735  | 0.0240  | 0.0960  | 0.4544 | 25588.65              |



# Zero-Shot ve Fine-Tuned Karşılaştırması

SmolLM2 ve TinyLlama modellerinde fine-tuning sonrasında ROUGE metriklerinde artış gözlenmiştir. Qwen2.5-1.5B modelinde ise ROUGE-1 ve ROUGE-L değerleri hafif artmış, BLEU değeri ise düşmüştür. Bu durum fine-tuning sonrasında modelin referans özetlerle birebir n-gram benzerliğinin azaldığını, ancak ROUGE bakımından içerik örtüşmesini kısmen artırdığını düşündürmektedir.

| Model          | Durum      | ROUGE-1 | ROUGE-2 | ROUGE-L | BLEU   | Inference ms/örnek |
|----------------|------------|---------|---------|---------|--------|--------------------|
| SmolLM2-360M   | Zero-shot  | 0.0878  | 0.0016  | 0.0536  | 0.1473 | 12872.69           |
| SmolLM2-360M   | Fine-tuned | 0.1295  | 0.0030  | 0.0743  | 0.0811 | 17182.38           |
| TinyLlama-1.1B | Zero-shot  | 0.0891  | 0.0079  | 0.0534  | 0.0217 | 11528.50           |
| TinyLlama-1.1B | Fine-tuned | 0.1118  | 0.0080  | 0.0681  | 0.0580 | 12063.76           |
| Qwen2.5-1.5B   | Zero-shot  | 0.1735  | 0.0240  | 0.0960  | 0.4544 | 25588.65           |
| Qwen2.5-1.5B   | Fine-tuned | 0.1822  | 0.0254  | 0.0977  | 0.4085 | 26652.82           |



# Sonuç ve Öğrenilen Dersler

## •Sonuçlar

- Qwen en başarılı model
- SmolLM beklenenden iyi çıktı
- TinyLlama kararlı fakat düşük performans verdi
- Veri seti çok küçük olduğu için performans sınırlı kaldı

## •Gelecek Çalışmalar

- 200–500 örnek
- Uzman doğrulamalı özetler
- Gemma 4 E2B
- BERTScore
- İnsan değerlendirmesi



# **TÜRKÇE HUKUKİ METİNLERİN ÖZETLENMESİNDE KÜÇÜK DİL MODELLERİ VE KNOWLEDGE DISTILLATION TABANLI BİR YAKLAŞIM**

## **Teşekkür Ederiz.**

**1. Yazar Keziban Karagümüş**