



TÜRKÇE HUKUKİ METİNLERİN ÖZETLENMESİNDE KÜÇÜK DİL MODELLERİ VE KNOWLEDGE DISTILLATION TABANLI BİR YAKLAŞIM

Keziban KARAGUMUS
258273001002



SUNUM PLANI

- Problem Tanımı
- Motivasyon
- Veri Seti Oluşturma Süreci
- Knowledge Distillation Yaklaşımı
- Kullanılan Modeller Fine-Tuning Stratejisi
- Deney Ortamı
- Sonuçlar



PROBLEM TANIMI

•Amaç:

Uzun Danıştay kararlarını kısa ve anlamlı hukuki özetlere dönüştürmek.

Girdi:

- Dava konusu
- Tarafların iddiaları
- Maddi olay
- Hukuki değerlendirme
- Karar sonucu

Çıktı:

- 6-8 cümlelik hukuki özet

Zorluk:

- Çok uzun metinler
- Teknik hukuk dili
- Karar mantığının korunması gerekliliği



NEDEN BU PROBLEM ÖNEMLİ?

- **Hukuki metinler**
 - Uzunudur
 - Karmaşıktır
 - Teknik terminoloji içerir
- **Manuel inceleme**
 - Çok zaman alır
- **Otomatik özetleme**
 - Hukukçular için zaman kazancı
 - Karar inceleme süreçlerinde hız



VERİ PROBLEMİ

- Hukuki özetleme çalışmalarındaki en büyük problem:
- Referans özet eksikliği**
- Danıştay kararlarının çoğunda:
- Kalıplaşmış yapılar bulunmakta
- Bu nedenle:
- Knowledge Distillation yaklaşımı kullanıldı**
- Teacher Model:
- ChatGPT
- Student Models:
- SmolLM2
- TinyLlama
- Qwen



VERİ SETİ OLUŞTURMA

Özellik	Değer
Karar Sayısı	40
Özet Sayısı	40
Kategori Sayısı	10

Kategoriler:

Çevre
Disiplin
Eğitim
İhale
İmar
Kamu Personeli
Ruhsat-Lisans
Sağlık
Sosyal Güvenlik
Vergi



ÖĞRETMEN MODEL (TEACHER MODEL)

Neden Teacher Model kullandık?

- Gerçek özet veri seti bulunmuyor.
- Kararlar oldukça kalıplaşmış yapıda.
- Student modellerin öğrenebilmesi için referans özet gerekli.
- Teacher Model:

ChatGPT

- Görev:
- Uzun Danıştay kararlarından yüksek kaliteli özet üretmek.



KULLANILAN PROMPT

- Aşağıdaki Danıştay kararını hukuki anlamını koruyarak özetle.

Özette:

- Davanın konusu
- Tarafların iddiaları
- Hukuki değerlendirme
- Karar sonucu yer alsın.

Özet:

- 6–8 cümle olsun
- Karar numarası verme
- Kişi isimleri verme
- Yeni bilgi ekleme
- Hukuki anlamı değiştirme



VERİ SETİ BÖLME

Bölüm	Sayı	Oran
Train	32	%80
Validation	4	%10
Test	4	%10

Random State:
42



KULLANILAN MODELLER

Model	Parametre
SmolLM2	360M
TinyLlama	1.1B
Qwen2.5	1.5B



NEDEN QLoRA?

QLoRA

Avantajlar:

- Düşük GPU belleği
- Hızlı eğitim
- Düşük maliyet
- Colab uyumluluğu



HİPERPARAMETRELER

Hiperparametre	Değer
Epoch	3
Learning rate	2e-4
Batch size	1
Gradient accumulation steps	4
Max sequence length	1024
LoRA rank	8
LoRA alpha	16
LoRA dropout	0.05
Target modules	q_proj, v_proj
Quantization	4-bit
Seeds	42, 123, 2026



DENEY ORTAMI

Deneyler Google Colab GPU ortamında gerçekleştirilmiştir. Eğitim sürecinde 4-bit quantization ve QLoRA kullanılmıştır.

Kullanılan başlıca kütüphaneler:

transformers

accelerate

peft

bitsandbytes

torch

pandas

numpy

scikit-learn

evaluate

rouge_score

sacrebleu

sentencepiece

matplotlib



Değerlendirme Metrikleri

Bu görev bir üretim görevi olduğu için aşağıdaki metrikler kullanılmıştır:

- ROUGE-1
- ROUGE-2
- ROUGE-L
- BLEU
- Inference süresi
- GPU bellek kullanımı
- Model boyutu

ROUGE metrikleri model çıktısı ile referans özet arasındaki örtüşmeyi ölçmektedir.

BLEU metriği ise n-gram tabanlı benzerliği değerlendirmektedir. Ayrıca modellerin pratik kullanılabilirliğini değerlendirmek için inference süresi, GPU bellek tüketimi ve adapter model boyutu da raporlanmıştır.



Eğitim Süreci Detayları

Her model 3 epoch boyunca eğitilmiştir. Learning rate $2e-4$, batch size 1 ve gradient accumulation steps 4 olarak kullanılmıştır. Deneyler üç farklı seed ile tekrar edilmiştir.




Eğitim Süresi, GPU Bellek ve Kayıp Değerleri

Model	Train Loss	Val Loss	Eğitim Süresi sn	GPU Bellek GB
SmolLM2-360M	2.6213 ± 0.0014	2.7904 ± 0.0009	44.04 ± 2.55	4.401 ± 0.001
TinyLlama-1.1B	2.1194 ± 0.0022	2.0759 ± 0.0061	117.69 ± 1.10	1.895 ± 0.006
Qwen2.5-1.5B	2.8108 ± 0.0055	2.9442 ± 0.0104	137.86 ± 8.64	3.912 ± 0.005




Loss Eğrileri


Qwen2.5-1.5B Loss Curve




SmolLM2-360M Loss Curve



TinyLlama-1.1B Loss Curve



Validation Loss Comparison





Loss Eğrileri

TinyLlama ve Qwen2.5 modellerinde validation loss değerleri düzenli biçimde azalmıştır. SmoLM2 modelinde validation loss hafif azalmış, ancak training loss artmıştır. Bu durum SmoLM2 eğitiminin daha kararsız ilerlediğini göstermektedir. Buna rağmen SmoLM2 tamamen başarısız olmamış ve bazı metriklerde TinyLlama'dan daha iyi sonuç üretmiştir.



Standart Sonuç Tablosu

Model	Parametre	FT Yöntemi	ROUGE-1	ROUGE-L	BLEU	Eğitim Süresi sn	Inferenç ms/örnek	GPU Bellek GB	Model Boyutu MB
SmolLM2-360M	360M	QLoRA	0.1295 ± 0.0032	0.0743 ± 0.0040	0.0811 ± 0.0061	44.04 ± 2.55	17182.38 ± 1052.13	4.401 ± 0.001	35.09
TinyLlama-1.1B	1.1B	QLoRA	0.1118 ± 0.0175	0.0681 ± 0.0087	0.0580 ± 0.0409	117.69 ± 1.10	12063.76 ± 2758.80	1.895 ± 0.006	46.78
Qwen2.5-1.5B	1.5B	QLoRA	0.1822 ± 0.0042	0.0977 ± 0.0034	0.4085 ± 0.1189	137.86 ± 8.64	26652.82 ± 866.93	3.912 ± 0.005	52.89



Zero-Shot Baseline

Zero-shot sonuçlarına göre Qwen2.5-1.5B modeli fine-tuning öncesinde de en yüksek performansı göstermiştir. Bu durum modelin çok dilli ön eğitim kapasitesinin Türkçe hukuki metinlerde avantaj sağladığını düşündürmektedir.

Model	ROUGE-1	ROUGE-2	ROUGE-L	BLEU	Inference ms/örnek
SmolLM2- 360M	0.0878	0.0016	0.0536	0.1473	12872.69
TinyLlama- 1.1B	0.0891	0.0079	0.0534	0.0217	11528.50
Qwen2.5- 1.5B	0.1735	0.0240	0.0960	0.4544	25588.65



Zero-Shot ve Fine-Tuned Karşılaştırması

SmolLM2 ve TinyLlama modellerinde fine-tuning sonrasında ROUGE metriklerinde artış gözlenmiştir. Qwen2.5-1.5B modelinde ise ROUGE-1 ve ROUGE-L değerleri hafif artmış, BLEU değeri ise düşmüştür. Bu durum fine-tuning sonrasında modelin referans özetlerle birebir n-gram benzerliğinin azaldığını, ancak ROUGE bakımından içerik örtüşmesini kısmen artırdığını düşündürmektedir.

Model	Durum	ROUGE-1	ROUGE-2	ROUGE-L	BLEU	Inference ms/örnek
SmolLM2-360M	Zero-shot	0.0878	0.0016	0.0536	0.1473	12872.69
SmolLM2-360M	Fine-tuned	0.1295	0.0030	0.0743	0.0811	17182.38
TinyLlama-1.1B	Zero-shot	0.0891	0.0079	0.0534	0.0217	11528.50
TinyLlama-1.1B	Fine-tuned	0.1118	0.0080	0.0681	0.0580	12063.76
Qwen2.5-1.5B	Zero-shot	0.1735	0.0240	0.0960	0.4544	25588.65
Qwen2.5-1.5B	Fine-tuned	0.1822	0.0254	0.0977	0.4085	26652.82



Sonuç ve Öğrenilen Dersler

•Sonuçlar

- Qwen en başarılı model
- SmolLM beklenenden iyi çıktı
- TinyLlama kararlı fakat düşük performans verdi
- Veri seti çok küçük olduğu için performans sınırlı kaldı

•Gelecek Çalışmalar

- 200–500 örnek
- Uzman doğrulamalı özetler
- Gemma 4 E2B
- BERTScore
- İnsan değerlendirmesi



TÜRKÇE HUKUKİ METİNLERİN ÖZETLENMESİNDE KÜÇÜK DİL MODELLERİ VE KNOWLEDGE DISTILLATION TABANLI BİR YAKLAŞIM

Teşekkür Ederiz.

1. Yazar Keziban Karagümüş